

LeadLeaf AI — Grafik Rehberi

Streamlit panosundaki her ekranın görüntüsü ve altında ne gösterdiği, nasıl okunduğu ve ne anlama geldiği.

Önce temel kavramlar

Ağırlık (parametre) nedir?

Bir yapay sinir ağı, içinde binlerce hatta milyonlarca sayı tutan bir hesap makinesidir. Bu sayılara ağırlık ya da parametre denir. Bir görüntü modele girince, piksellerin değerleri bu ağırlıklarla çarpılıp toplanır; sonuçta her hastalık için bir puan çıkar. Eğitim, bu sayıların doğru cevabı verecek şekilde yavaş yavaş ayarlanmasıdır. Yani modelin 'öğrendiği' her şey bu sayıların içindedir.

Evrişim ekranındaki 3x3 sayı tablosu (kenardaki ağırlıklar)

Evrişim ekranında solda gördüğünüz tablo $\begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}$ tek bir filtrenin 9 ağırlığıdır. Bu filtre görselin üzerinde 3x3 piksellik bir pencere gibi kaydırılır. Her konumda altındaki 9 piksel bu 9 sayıyla çarpılıp toplanır. Soldaki sütun eksi, sağdaki artı olduğu için: pencerenin solu ile sağı arasında parlaklık farkı varsa (yani dikey bir kenar varsa) sonuç büyük çıkar ve o nokta parlar; fark yoksa sonuç sıfıra yakındır ve karanlık kalır. Sağdaki siyah görselde yaprağın kenarlarının ve damarlarının parlamasının nedeni budur. Tablodaki sayılar değiştirilirse filtrenin aradığı desen de değişir.

Modelde bu filtreler nereden geliyor?

Ekrandaki filtreyi elle yazdık, ama gerçek modelde kimse filtre yazmaz. EfficientNetB0'ın içinde binlerce filtre vardır ve hepsinin sayıları eğitim sırasında kendiliğinden bulunmuştur. Bazıları kenar, bazıları renk, derindekiler leke ve doku gibi karmaşık desenler arar.

4.049.571 ve 48.678 sayıları ne?

'Projedeki model' ekranındaki 4.049.571, EfficientNetB0 gövdesindeki toplam ağırlık sayısıdır. Bunlar ImageNet adlı 1,28 milyon görsellik veriyle önceden eğitilmiş hâlde hazır gelir. 48.678 ise projede eklenen son katmandaki ağırlık sayısıdır: gövdenin çıkardığı 1.280 özelliği 38 hastalığa bağlayan katman ($1.280 \times 38 + 38 = 48.678$). Önce yalnızca bu 48.678 sayı eğitilmiş, sonra fine-tuning ile gövdenin son kısmındaki ağırlıklar da azar azar ayarlanmıştır.

Transfer learning bir benzetmeyle

Sıfırdan model eğitmek, hiç okuma bilmeyen birine hem okumayı hem tıbbi öğretmek gibidir. Transfer learning ise okumayı zaten bilen birine yalnızca tıbbi öğretmektir. ImageNet'te eğitilmiş model 'görmeyi' (kenar, renk, doku, şekil) biliyor; biz ona yalnızca bu desenleri yaprak hastalıklarına bağlamayı öğrettik. Bu yüzden daha az veri ve daha kısa sürede yüksek başarı elde edildi.

Proje Özeti

LeadLeaf AI

Yaprak fotoğrafından bitki hastalığı ön değerlendirmesi

Çiftçi Telegram'dan bir yaprak fotoğrafı gönderiyor. Model hastalığı tahmin ediyor, bilgi tabanından o hastalığa ait kaynak metin bulunuyor ve Claude bu kaynağa göre kısa bir rapor yazıyor. Emin olmadığı durumda sistem ziraat mühendisine yönlendiriyor.

Görsel 54.305	Bitki / Sınıf 14 / 38	Test doğruluğu %98,98	Model EfficientNet...
-------------------------	---------------------------------	---------------------------------	---------------------------------

Görev şablonu: DL → LLM-Agent → n8n

Bootcamp görevi: "Görüntüden Rapor (Vision → Agent → PDF)" — A) Tarım, bitki hastalığı tespiti



Kullanılan araçlar

Katman	Araç
Model eğitimi	TensorFlow / Keras, Google Colab (GPU)
Model servisi	FastAPI
Bilgi tabanı (RAG)	Chroma + sentence-transformers
Rapor	Claude (Anthropic API)
Akış	n8n
Kullanıcı arayüzü	Telegram botu
Kayıt	Google Sheets
Bu pano	Streamlit

Ekranda ne var?

Dört metrik kartı (görsel sayısı, bitki/sınıf, test doğruluğu, model adı), bootcamp görev şablonunun şeması ve kullanılan araçlar tablosu.

Nasıl okunur?

Şema yukarıdan aşağı okunur: fotoğraf → görüntü modeli (tahmin) → LLM-Agent (yorum ve rapor) → n8n (Telegram, PDF, Sheets gibi eylemler).

Ne anlama geliyor?

Proje, bootcamp'in 'DL → LLM-Agent → n8n' şablonuna birebir uyar. %98,98 doğruluk, modelin hiç görmediği 8.146 test görselinde ölçülmüştür.

Veri Seti: PlantVillage

Laboratuvarlarda, sade bir arka plan önünde çekilmiş yaprak fotoğrafları. Her klasör bir sınıf: bitki adı + hastalık adı (ya da sağlıklı).

Toplam görsel
54.305

Bitki
14

Sınıf
38

Hastalık sınıfı
26

Veri setinden örnek görseller

Bitki

Domates

Sınıf

- ☒ Sarı Yaprak Kıvrıklığı Virüsü
☐ Bakteriyel Leke
☐ Geç Yanıklık
☐ Septoria Yaprak Lekesi
☐ Kırmızı Örümcek
☐ Sağlıklı
☐ Hedef Leke
☐ Erken Yanıklık
☐ Yaprak Küfü
☐ Mozaik Virüsü

Bu sınıftaki görsel
5.357

Başka örnekler göster



Klasör: Tomato Tomato Yellow Leaf Curl Virus · Görseller 256×256 piksel

☐ Mozaik Virüsü

Bu sınıftaki görsel
5.357

Başka örnekler göster



Klasör: Tomato Tomato Yellow Leaf Curl Virus · Görseller 256×256 piksel

İki sınıfın karşılaştırılması

Bazı hastalıklar birbirine çok benzemektedir; modelin işini zorlaştıran da budur.

Birinci sınıf

Domates — Erken Yanıklık

İkinci sınıf

Domates — Hedef Leke



> Tüm sınıflar ve görsel sayıları

← Proje Özeti

2 / 11

Keşifsel Veri Analizi →

Ekranda ne var?

Seilen bitki ve hastalıęa ait 12 gerek yaprak fotoęrafı; altta iki hastalıęın yan yana karşılaştırması.

Nasıl okunur?

Soldan bitki ve sınıf seçilir; sağda o sınıfın örnekleri görünür.

Ne anlama geliyor?

Fotoęrafların hepsi laboratuvarıda, gri zemin önünde, tek yaprak olarak ekilmiştir. Karşılaştırmada erken yanıklık ile hedef lekenin ne kadar benzedięi görülür; model en ok bu tür benzer hastalıklarda zorlanır.

Keşifsel Veri Analizi — Sınıf dağılımı

Keşifsel Veri Analizi

Sınıf dağılımı Eğitim / Doğrulama / Test Görsel özellikleri Veri kalitesi

En büyük sınıf

5.507

↑ Portakal — Turuncgil Yeşillenmesi

En küçük sınıf





152

↑ Patates — Sağlıklı

Oran

36 kat

Bitkilere göre




Her bitkinin veri setindeki görsel sayısı. Koyu lacivert hastalıklı, açık mavi sağlıklı yaprakları gösterir. Halka grafik tüm veride hastalıklı ve sağlıklı oranını verir.

BULGU

Veri bitkiler arasında eşit dağılmamıştır: domates 18.160 görselle en büyük bitkidir, ahududu yalnızca 371 görseldir. Görsellerin %72'si hastalıklı, %28'i sağlıklı yapraklıdır.

Sınıflara göre (bir bitkiye tıklandığında o bitkinin sınıfları vurgulanır)



38 sınıfın her birindeki görsel sayısı, büyüken küçüğe sıralı.

BULGU

En büyük sınıf (portakal HLB, 5.507) en küçükten (sağlıklı patates, 152) yaklaşık 36 kat büyüktür. Bu dengesizlik yüzünden yalnızca doğruluğa değil, her sınıfı eşit sayan macro F1 skoruna da bakılmıştır.

← Veri Seti

3 / 11

CNN ve Transfer Learning →

Ekranda ne var?

Üstte en büyük ve en küçük sınıf; solda bitkilere göre görsel sayısı (koyu: hastalıklı, açık: sağlıklı) ve halka grafik; sağda 38 sınıfın görsel sayısı.

Nasıl okunur?

Çubuk ne kadar uzunsa o bitkiden ya da sınıftan o kadar çok görsel vardır. Halka grafikte koyu kısım hastalıklı, açık kısım sağlıklı yaprakların payıdır.

Ne anlama geliyor?

Veri dengesizdir: domates 18.160 görselle en büyük, ahududu 371 görselle en küçük bitkidir; en büyük sınıf en küçükten 36 kat büyüktür. Bu yüzden yalnızca doğruluğa bakmak yetmez; her sınıfı eşit sayan macro F1 de raporlanmıştır. Görsellerin %72'si hastalıklıdır.


Keşifsel Veri Analizi — Eğitim / Doğrulama / Test

Keşifsel Veri Analizi

Sınıf dağılımı Eğitim / Doğrulama / Test Görsel özellikleri Veri kalitesi

Veri, eğitimden önce **bir kez** bölünmüştür: her sınıfın kendi içinde %70 eğitim, %15 doğrulama, %15 test. Rastgelelik sabit (seed = 42), yani aynı bölme tekrar üretilmektedir. Hangi dosyanın hangi kümeye gittiği bir dosyada kayıtlıdır.

Eğitim 38.013 ↑ modelin öğrendiği	Doğrulama 8.146 ↑ eğitim sırasında kontrol	Test 8.146 ↑ en sonda, bir kez
--	---	---



← Veri Seti

3 / 11

CNN ve Transfer Learning →

Ekranda ne var?

Üç kümenin görsel sayısı ve her sınıfın bu üç kümeye nasıl paylaştırıldığını gösteren yatay çubuklar.

Nasıl okunur?

Her çubuk bir sınıftır ve %100'e tamamlanır. Koyu lacivert eğitim, orta mavi doğrulama, açık mavi test payıdır.

Ne anlama geliyor?

Eğitim kümesi (%70) modelin öğrendiği görsellerdir. Doğrulama (%15) eğitim sırasında 'model iyi gidiyor mu?' diye bakılan, test (%15) ise en sonda bir kez kullanılan ve modelin hiç görmediği görsellerdir. Bütün çubuklarda renk sınırları aynı hizada olduğu için bölme her sınıfta aynı oranda yapılmıştır.

Keşifsel Veri Analizi — GörSEL özellikleri

Keşifsel Veri Analizi


Sınıf dağılımı Eğitim / Doğrulama / Test GörSEL özellikleri Veri kalitesi

GörSEL boyutları (54.305 görSELin hepsi)

Boyut	Adet
256x256	54305

Hepsi aynı boyutta. Modele girmeden önce 224x224'e küçültülüyor.

Parlaklık dağılımı (her sınıftan 60 görSEL)




Her sınıftan 60 görSELin ortalama parlaklığı (0 siyah, 255 beyaz).

BULGU

Sınıflar arasında parlaklık farkı vardır: en koyu mısır pası (ortanca 89), en parlak sağlıklı mısır (ortanca 142). Model rengi ve ışığı da öğrenebileceği için tarla fotoğraflarında bu fark sorun yaratabilir.

Renk: yeşil kanal ile kırmızı kanal



Her nokta bir görSEL. Yatay eksen ortalama kırmızı, dikey eksen ortalama yeşil değeridir.


BULGU

Hastalıklı yapraklar ortalama daha koyu ve daha az yeşildir: yeşil kanal 122'ye karşı 137, kırmızı kanal 117'ye karşı 127. Renk tek başına hastalığı ayırmaya yetmez; iki grup büyük ölçüde iç içedir.

BULGU

Sınıflar arasında parlaklık farkı vardır: en koyu mısır pası (ortanca 89), en parlak sağlıklı mısır (ortanca 142). Model rengi ve ışığı da öğrenebileceği için tarla fotoğraflarında bu fark sorun yaratabilir.

Renk: yeşil kanal ile kırmızı kanal



Her nokta bir görsel. Yatay eksen ortalama kırmızı, dikey eksen ortalama yeşil değeridir.

BULGU

Hastalıklı yapraklar ortalamada daha koyu ve daha az yeşildir: yeşil kanal 122'ye karşı 137, kırmızı kanal 117'ye karşı 127. Renk tek başına hastalığı ayırmaya yetmez; iki grup büyük ölçüde iç içedir.

← Veri Seti

3 / 11

CNN ve Transfer Learning →

Ekranda ne var?

Görsel boyutları tablosu, her sınıfın parlaklık kutu grafiği ve kırmızı-yeşil renk dağılımı.

Nasıl okunur?

Kutu grafikte kutu görsellerin ortadaki yarısını, kutunun içindeki çizgi ortanca değeri gösterir. Renk grafiğinde her nokta bir görseldir: sağa gittikçe kırmızı, yukarı gittikçe yeşil artar.

Ne anlama geliyor?

Bütün görseller 256x256 pikseldir. Sınıflar arasında parlaklık farkı vardır (en koyu mısır pası, en parlak sağlıklı mısır). Hastalıklı yapraklar ortalamada daha koyu ve daha az yeşildir; ama renk tek başına hastalığı ayırmaya yetmez, iki grup iç içedir.

Keşifsel Veri Analizi

Sınıf dağılımı Eğitim / Doğrulama / Test Görsel özellikleri Veri kalitesi

Birebir aynı görsel grubu

21

Fazladan kopya

21

Farklı sınıfta aynı görsel

0


Her dosyanın içeriğinden bir özet (MD5) çıkarılıp karşılaştırılmıştır. Aynı özete sahip iki dosya birebir aynı fotoğraftır. Aynı fotoğrafın bir kopyası eğitimde, diğeri testte olursa model onu ezberden bilir ve sonuç olduğundan iyi görünür.

Bulgu: 21 tekrar grubundan 9 tanesinin kopyaları farklı kümelere düşmüş. Bunlardan 3 test görselinin birebir aynısı eğitim kümesinde var. Yani model bu 3 görseli aslında eğitimde gördü. 8.146 test görselinin içinde bu en fazla %0.04'lik bir etki; sonucu değiştirmiyor ama bölmeden önce tekrarları temizlemek daha doğru olurdu.

> Farklı kümelere düşen kopyalar

Bozuk ya da açılmayan görsel yok: 54.305 görselin hepsi tam olarak açılıp okundu.

Bulgu: 1 dosya fotoğraf değil, ekran görüntüsü (PNG): Pepper_healthy/42f083e2-272d-4f83-ad9a-573ee90e50ec__Screen Shot 2015-05-06 at 4.01.13 PM.png. Veri setine yanlışlıkla girmiş ve test kümesine düşmüş. Model bunu %69,1 güvenle 'domates erken yanıklık' sandı; güven %70'in altında olduğu için bot uzmana yönlendirildi.



21

21

0

Her dosyanın içeriğinden bir özet (MD5) çıkarılıp karşılaştırılmıştır. Aynı özete sahip iki dosya birebir aynı fotoğraftır. Aynı fotoğrafın bir kopyası eğitimde, diğeri testte olursa model onu ezberden bilir ve sonuç olduğundan iyi görünür.

Bulgu: 21 tekrar grubundan 9 tanesinin kopyaları farklı kümelere düşmüş. Bunlardan 3 test görselinin birebir aynısı eğitim kümesinde var. Yani model bu 3 görseli aslında eğitimde gördü. 8.146 test görselinin içinde bu en fazla %0.04'lik bir etki; sonucu değiştirmiyor ama bölmeden önce tekrarları temizlemek daha doğru olurdu.

> Farklı kümelere düşen kopyalar

Bozuk ya da açılmayan görsel yok: 54.305 görselin hepsi tam olarak açılıp okundu.

Bulgu: 1 dosya fotoğraf değil, ekran görüntüsü (PNG): Pepper_healthy/42f083e2-272d-4f83-ad9a-573ee90e50ec__Screen Shot 2015-05-06 at 4.01.13 PM.png. Veri setine yanlışlıkla girmiş ve test kümesine düşmüş. Model bunu %69,1 güvenle 'domates erken yanıklık' sandı; güven %70'in altında olduğu için bot uzmana yönlendirildi.



← Veri Seti

3 / 11

CNN ve Transfer Learning →

Ekranda ne var?

Birebir aynı görsel sayıları, farklı kümelerle düşen kopyalar ve veri setinde bulunan ekran görüntüsü.

Nasıl okunur?

Her dosyanın içeriğinden bir özet çıkarılıp karşılaştırılmıştır; özeti aynı olan iki dosya aynı fotoğraftır.

Ne anlama geliyor?

21 fotoğraf veri setinde iki kez vardır; bunlardan 3 test görselinin aynısı eğitimde bulunur. Etkisi en fazla %0,04'tür, sonucu değiştirmez. Biber klasöründe bir ekran görüntüsü bulunmuştur; model onu %69 güvenle yanlış tahmin etmiş, güven %70'in altında olduğu için sistem uzmana yönlendirdi.

CNN — Evrişim (filtre) denemesi

CNN ve Transfer Learning

Evrişim (convolution) Neden transfer learning? Projedeki model Katmanlar ne görüyor?

CNN'in temel işlemi: küçük bir filtre (3×3 sayı) görselin üzerinde kaydırılır. Her konumda filtre ile altındaki pikseller çarpılıp toplanır. Filtre neyi arıyorsa o bölgeler parlar. Aşağıda bir filtre seçilerek ya da sayılar değiştirilerek sonuç görülebilir.

Yaprak

Domates — Erken Yanıklık


Hazır filtre

- ☒ Dikey kenar
☐ Yatay kenar
☐ Keskinleştirme
☐ Bulanıklaştırma

≡ 1	≡ 2	≡ 3
-1	0	1
-2	0	2
-1	0	1



Orijinal



Filtre sonrası: Dikey kenar

Gerçek bir CNN'de bu filtreler elle yazılmaz; model eğitim sırasında bunları kendisi öğrenir. İlk katmanlar kenar ve renk geçişi gibi basit şeyler, son katmanlar leke ve doku gibi daha karmaşık şeyler öğreniyor.

Seçilen yaprak (ortada) ve üzerine 3×3'lük bir filtre uygulanmış hâli (sağda).

BULGU

CNN'in temel işlemi budur: küçük bir filtre görselin üzerinde gezer ve belirli desenleri öne çıkarır. Gerçek modelde bu filtreler elle yazılmaz, eğitim sırasında öğrenilir.

← Keşifsel Veri Analizi

4 / 11

Model Karşılaştırma →

Evrişim (convolution) Neden transfer learning? Projedeki model Katmanlar ne görüyor?

CNN'in temel işlemi: küçük bir filtre (3×3 sayı) görselin üzerinde kaydırılır. Her konumda filtre ile altındaki pikseller çarpılıp toplanır. Filtre neyi arıyorsa o bölgeler parlar. Aşağıda bir filtre seçilerek ya da sayılar değiştirilerek sonuç görülebilir.

Yaprak

Domates — Erken Yanıklık


Hazır filtre

- ☒ Dikey kenar
☐ Yatay kenar
☐ Keskinleştirme
☐ Bulanıklaştırma

≡ 1	≡ 2	≡ 3
-1	0	1
-2	0	2
-1	0	1



Orijinal



Filtre sonrası: Dikey kenar

Gerçek bir CNN'de bu filtreler elle yazılmaz; model eğitim sırasında bunları kendisi öğrenir. İlk katmanlar kenar ve renk geçişi gibi basit şeyler, son katmanlar leke ve doku gibi daha karmaşık şeyler öğreniyor.

Seçilen yaprak (ortada) ve üzerine 3×3'lük bir filtre uygulanmış hâli (sağda).

BULGU

CNN'in temel işlemi budur: küçük bir filtre görselin üzerinde gezer ve belirli desenleri öne çıkarır. Gerçek modelde bu filtreler elle yazılmaz, eğitim sırasında öğrenilir.

← Keşifsel Veri Analizi

4 / 11

Model Karşılaştırma →

Ekranda ne var?

Solda yaprak seçimi, filtre seçimi ve filtrenin 3x3 ağırlık tablosu; ortada orijinal yaprak, sağda filtre uygulanmış hâli.

Nasıl okunur?

Sağdaki görselde parlak yerler filtrenin aradığı desenin bulunduğu yerlerdir. Filtre değiştirildikçe ya da tablodaki sayılar düzenlendikçe sağdaki görsel değişir (ağırlıkların anlamı için rehberin başına bakınız).

Ne anlama geliyor?

CNN'in yaptığı en temel iş budur: küçük filtreler görselin üzerinde gezer ve kenar, çizgi, leke gibi desenleri öne çıkarır. Gerçek modelde binlerce filtre vardır ve sayıları eğitimle bulunur.

CNN — Neden transfer learning?

CNN ve Transfer Learning

Evrişim (convolution) Neden transfer learning? Projedeki model Katmanlar ne görüyor?

İki yol vardı: sıfırdan bir CNN yazıp eğitmek ya da daha önce milyonlarca görselle eğitilmiş bir modeli alıp bu veriye uyarlamak (transfer learning). Projede ikincisi tercih edilmiştir.

	Sıfırdan CNN	Transfer learning
0 Başlangıç	Rastgele ağırlıklar, hiçbir şey bilmiyor	ImageNet'te (1,28 milyon görsel, 1000 sınıf) eğitilmiş
1 Gereken veri	Çok fazla	Daha az yeter
2 Eğitim süresi	Uzun	Kısa
3 Ezberleme riski	Yüksek	Daha düşük
4 Projenin koşulları	Colab'ın ücretsiz GPU'su ve kısıtlı süre	Kenar, doku, şekil bilgisi hazır geliyor

Yaprak da sonuçta bir görsel. Kenar, doku, renk geçişi gibi temel özellikleri ImageNet'te öğrenmiş bir model bunları yaprakta da kullanabilir. Bu projede yalnızca son kısım 38 sınıfa göre eğitilmiştir.

Not: Sıfırdan eğitilen bir CNN ile ayrıca karşılaştırma yapılmamıştır. Bu bir sonraki adım olarak yapılabilir; literatürde PlantVillage'da transfer learning'in sıfırdan eğitime göre daha iyi sonuç verdiği biliniyor.

← Keşifsel Veri Analizi

4 / 11

Model Karşılaştırma →

Ekranda ne var?

Sıfırdan CNN eğitimi ile transfer learning'in karşılaştırma tablosu.

Nasıl okunur?

Tablo satır satır okunur: başlangıç noktası, gereken veri, süre, ezberleme riski ve projenin koşulları.


Ne anlama geliyor?

Sıfırdan eğitim çok veri ve uzun GPU süresi ister; proje Colab'ın ücretsiz GPU'suyla sınırlıydı. Hazır modelin 'görme' bilgisi kullanıldığı için daha az veriyle yüksek başarıya ulaşılmıştır.

CNN — Projedeki model

CNN ve Transfer Learning

Evrişim (convolution) Neden transfer learning? Projedeki model Katmanlar ne görüyor?



Ekranda ne var?

Üç metrik (gövde katman sayısı, gövde parametresi, eklenen katman parametresi) ve modelin katman şeması.

Nasıl okunur?

Şema soldan sağa okunur: 224x224 görsel girer → eğitimde veri artırma uygulanır → EfficientNetB0 gövdesi özellik çıkarır → 1.280 sayıya indirilir (Global Average Pooling) → Dropout → 38 sınıf için olasılık (softmax).

Ne anlama geliyor?

Modelin büyük kısmı (4 milyon ağırlık) hazır gelmiştir; projede eklenen kısım 48.678 ağırlıktır. Softmax her hastalığa bir olasılık verir, en yüksek olan tahmin ve o olasılık da 'güven' değeridir.

CNN — Katmanlar ne görüyor?

CNN ve Transfer Learning

[Evrışım \(convolution\)](#) [Neden transfer learning?](#) [Projedeki model](#) [Katmanlar ne görüyor?](#)


Bir yaprak modele verilip gövdenin farklı derinliklerindeki çıktılar gösterilmektedir. Her küçük kare bir filtrenin tepkisi: parlak yerler, o filtrenin "bir şey bulduğu" yerler.

Yaprak


Domates — Geç Yapraklık




Başta (stem) · [stem_activation](#) · çıktı boyutu 112×112, 32 filtre




Ortada (blok 3) · [block3b_activation](#) · çıktı boyutu 28×28, 240 filtre



Derinde (blok 6) · [block6d_activation](#) · çıktı boyutu 7×7, 1152 filtre



Ortada (blok 3) · [block3b_activation](#) · çıktı boyutu 28×28, 240 filtre



Derinde (blok 6) · [block6d_activation](#) · çıktı boyutu 7×7, 1152 filtre



Başta çıktı büyük (112×112) ve yaprağın şekli seçiliyor. Derine indikçe çıktı küçülüyor (14×14), filtre sayısı artıyor ve neyi gördüğü insan gözüyle zor anlaşılıyor: model artık şekil yerine leke, doku gibi soyut özelliklere bakıyor.

Aynı yaprağın modelin başındaki, ortasındaki ve derindeki katmanlarda nasıl görüldüğü. Her kare bir filtrenin çıktısıdır.

BULGU

Model ilk katmanlarda yaprağın kenarını ve şeklini, derin katmanlarda leke ve doku gibi hastalığa özgü desenleri yakalamaktadır. Karar en derindeki bu desenlere göre verilir.

← Keşifsel Veri Analizi

4 / 11

Model Karşılaştırma →

Ekranda ne var?

Seilen yaprak ve modelin bařındaki, ortasındaki ve derindeki katmanlardan 8'er filtre ıktısı.

Nasıl okunur?

Her küçük kare bir filtrenin yaprağı verdiğı tepkidir; parlak yerler filtrenin bir şey bulduğı yerlerdir. Ařağı indike kareler bulanıklařır, ünkü özünürlük düşer ($112 \rightarrow 28 \rightarrow 14$ piksel).

Ne anlama geliyor?

Model bařta yaprağın řeklini ve kenarlarını görür; derine indike leke ve doku gibi hastalığı özgü desenlere odaklanır. Son karar en derindeki bu desenlere göre verilir.

Model Karşılaştırma

Model Karşılaştırma

Model seçimi tahmine göre yapılmamıştır. Üç hazır model aynı veriye, aynı ayarlarla eğitilip test setinde karşılaştırılmıştır. Bu deney hız için domatesin 5 sınıfıyla yapılmış, kazanan model daha sonra 38 sınıfa taşınmıştır.

Neden bu üç model?

MobileNetV2

Telefonlar için tasarlanmış, hafif ve hızlı. Sık kullanılan bir başlangıç noktası.

MobileNetV3Small

MobileNet'in daha da küçük hali. "En küçük model ne kadar iyi olur?" sorusunun cevabı için.


EfficientNetB0

Az parametreyle yüksek doğruluk için tasarlanmış. Literatürde bitki hastalığı sınıflandırmada iyi sonuç veriyor.

Üçü de ücretsiz Colab GPU'sunda makul sürede eğitilebilecek kadar küçük modeller.

Metrik

☒ Doğruluk ☐ Macro F1 ☐ Macro Precision ☐ Macro Recall ☐ Macro AUC



Eksen %80'den başlıyor; farklar daha net görünsün diye. Yeşil çubuk üretimde kullanılan eğitim tarifi.

Üç modelin ve fine-tuning sonrası EfficientNetB0'ın test setindeki başarısı. Üstteki seçeneğe metrik değiştirilebilir.

BULGU

Aynı veri ve aynı ayarlarla en iyi sonucu EfficientNetB0 vermiştir (%94,68). Fine-tuning tarifiyle geliştirilmesiyle %97,62'ye çıkmıştır; bu yüzden üretimde bu model kullanılmaktadır.


Boyut, hız ve doğruluk birlikte

Tablo

BULGU

Aynı veri ve aynı ayarlarla en iyi sonucu EfficientNetB0 vermiştir (%94,68). Fine-tuning tarifiyle geliştirilmesiyle %97,62'ye çıkmıştır; bu yüzden üretimde bu model kullanılmaktadır.

Boyut, hız ve doğruluk birlikte



Tablo

Model	Doğruluk	Macro F1	AUC
MobileNetV2	90.95%	0.898	0.988
MobileNetV3Small	87.94%	0.852	0.987
EfficientNetB0 (ilk tarif)	94.68%	0.940	0.996
EfficientNetB0 (fine-tuning sonrası)	97.62%	0.972	0.999

EfficientNetB0 en yüksek doğruluk ve F1'i verdi. Boyutu biraz daha büyük ama modeli sunucuda çalıştığı için boyut farkı önemli değildir. Süreler birbirine yakındır (~90 ms).

Her balon bir model. Yatay eksen boyut (MB), dikey eksen doğruluk, balonun büyüklüğü bir görselin işleme süresi.

BULGU


MobileNetV3Small en küçük (9,7 MB) ama en az doğru modeldir. EfficientNetB0 biraz daha büyüktür ama en doğrusudur; sunucuda çalıştığı için boyut farkı önemli değildir. Süreler birbirine yakındır (~90 ms).

Eğitim grafikleri (Colab çıktıları)

Model

EfficientNetB0 (ilk tarif)


Öğrenme eğrisi (eğitim ve doğrulama) Karşıklık matrisi (test)



Model

EfficientNetB0 (ilk tarif)

Öğrenme eğrisi (eğitim ve doğrulama) Karşıklık matrisi (test)



Öğrenme eğrisinde eğitim ve doğrulama çizgilerinin birbirine yakın gitmesi, modelin ezberlemediğini gösterir. MobileNetV3Small'da fine-tuning başlayınca doğrulama doğruluğu düşmüştür: küçük model bu ayara iyi tepki vermemiştir.

Öğrenme eğrisi: her epoch sonunda eğitim (mavi) ve doğrulama (turuncu) doğruluğu ile kaybı. Karşıklık matrisi: test görsellerinin hangi sınıfa tahmin edildiği.

BULGU

EfficientNetB0'da fine-tuning başlayınca eğitim doğruluğu kısa bir süre düşüp toparlanmış, doğrulama çizgisi eğitim çizgisinden ayrılmamıştır. MobileNetV3Small'da ise fine-tuning sonrası doğrulama düşmüştür.

← CNN ve Transfer Learning

5 / 11

Fine-Tuning →

Ekranda ne var?

Üç modelin test başarısı (çubuk grafik), boyut-doğruluk-hız karşılaştırması (balon grafik), sonuç tablosu ve öğrenme eğrisi.

Nasıl okunur?

Çubukta uzun olan daha başarılıdır (eksen %80'den başlar). Balon grafikte sol üst hem küçük hem doğru demektir; balonun büyüklüğü hızı gösterir. Öğrenme eğrisinde mavi eğitim, turuncu doğrulama doğruluğudur; kesikli çizgi fine-tuning'in başladığı yerdir.

Ne anlama geliyor?

Aynı veri ve ayarlarla en iyi sonucu EfficientNetB0 vermiştir (%94,7); eğitim tarifi geliştirilince %97,6'ya çıkmıştır. Eğitim ve doğrulama çizgilerinin birbirine yakın gitmesi modelin ezberlemediğini gösterir.

Model Karşılaştırma — Karışıklık matrisi (5 sınıf)

Model boyutu (MB)

- EfficientNetB0 (fine-tuni...)
- EfficientNetB0 (ilk tarif)
- MobileNetV2
- MobileNetV3Small

EfficientNetB0 en yüksek doğruluk ve F1'i verdi. Boyutu biraz daha büyük ama modeli sunucuda çalıştığı için bu bir sorun oluşturmamaktadır.

Her balon bir model. Yatay eksen boyut (MB), dikey eksen doğruluk, balonun büyüklüğü bir görselin işlenme süresi.

BULGU


MobileNetV3Small en küçük (9,7 MB) ama en az doğru modeldir. EfficientNetB0 biraz daha büyüktür ama en doğrusudur; sunucuda çalıştığı için boyut farkı önemli değildir. Süreler birbirine yakındır (~90 ms).

Eğitim grafikleri (Colab çıktıları)


Model

EfficientNetB0 (ilk tarif)

Öğrenme eğrisi (eğitim ve doğrulama) Karışıklık matrisi (test)



Öğrenme eğrisi (eğitim ve doğrulama) Karışıklık matrisi (test)



Öğrenme eğrisinde eğitim ve doğrulama çizgilerinin birbirine yakın gitmesi, modelin ezberlemediğini gösterir. MobileNetV3Small'da fine-tuning başlayınca doğrulama doğruluğu düşmüştür; küçük model bu ayarda iyi tepki vermemiştir.

Öğrenme eğrisi: her epoch sonunda eğitim (mavi) ve doğrulama (turuncu) doğruluğu ile kaybı. Karışıklık matrisi: test görsellerinin hangi sınıfa tahmin edildiği.

BULGU

EfficientNetB0'da fine-tuning başlayınca eğitim doğruluğu kısa bir süre düşüp toparlanmış, doğrulama çizgisi eğitim çizgisinden ayrılmamıştır. MobileNetV3Small'da ise fine-tuning sonrası doğrulama düşmüştür.

← CNN ve Transfer Learning

5 / 11

Fine-Tuning →

Ekranda ne var?

Domatesin 5 sınıfındaki test sonuçlarının tablosu.

Nasıl okunur?

Satırlar gerçek sınıf, sütunlar modelin tahminidir. Köşegendeki koyu kareler doğru tahminler, köşegen dışındaki renkli kareler karışmalardır.

Ne anlama geliyor?

Köşegen koyu, dışı açık olduğu için model çoğunlukla doğru tahmin etmektedir; en çok karışan sınıf erken yanıklıdır.

Fine-Tuning (İnce Ayar)

Transfer learning'de önce hazır modelin gövdesi **dondurulur**, yani ağırlıkları değiştirilmez ve yalnızca en sona eklenen sınıflandırma katmanı eğitilir. Fine-tuning, bundan sonra gövdenin **son katmanlarını da açıp** çok küçük adımlarla projenin verisine göre ayarlamak demek.

Neden son katmanlar?

İlk katmanlar kenar ve renk gibi her görselde işe yarayan şeyler öğreniyor, onlara dokunmaya gerek yok. Son katmanlar ise ImageNet'in sınıflarına göre şekillenmiş; yaprak hastalıklarına uyması gereken kısım orası.

Neden küçük öğrenme oranı?

İlk aşamada öğrenme oranı 0,001. Fine-tuning'de 0,00001, yani 100 kat küçük. Büyük adımlarla gidersek modelin ImageNet'ten getirdiği bilgiyi birkaç adımda bozarız.

Uygulanan yöntem: kademeli açma



Parametre sayıları üretim modelinin katmanlarından hesaplandı. Toplam parametre: 4,098,249. Son aşamada bile gövdenin büyük kısmı sabit kalıyor.

Fine-tuning'in her aşamasında eğitilen (güncellenen) parametre sayısı.

BULGU

Eğitim kademeli yapılmıştır: önce yalnızca son katman, sonra gövdenin son %15, %30 ve %40'ı. Böylece modelin ImageNet'ten getirdiği bilgi bir anda bozulmamıştır.

Her aşamada iki yardımcı var:

- **ReduceLROnPlateau**: doğrulama kaybı 2 epoch düzelmezse öğrenme oranını yarıya indiriyor.
- **EarlyStopping**: doğrulama doğruluğu 5 epoch artmazsa duruyor ve en iyi epoch'un ağırlıklarına geri dönüyor.


Bir de **BatchNormalization** tuzağı var: gövdeyi açınca bu katmanlar kendi istatistiklerini küçük batch'lere göre değiştirmeye başlar ve model sessizce bozulur. Gövde `training=False` ile çağrılarak bu durum engellenmiştir.

Çıkarılan sonuçlar: aynı model, iki farklı eğitim

- **ReduceLROnPlateau**: doğrulama kaybı 2 epoch düzelmezse öğrenme oranını yarıya indiriyor.
- **EarlyStopping**: doğrulama doğruluğu 5 epoch artmazsa duruyor ve en iyi epoch'un ağırlıklarına geri dönüyor.

Bir de **BatchNormalization** tuzağı var: gövdeyi açınca bu katmanlar kendi istatistiklerini küçük batch'lere göre değiştirmeye başlar ve model sessizce bozulur. Gövde `training=False` ile çağrılarak bu durum engellenmiştir.

Sonuç: aynı model, iki farklı eğitim




Domates 5 sınıf deneyi. Bu tarif daha sonra 38 sınıfa aynen uygulanmıştır.

Aynı EfficientNetB0 modelinin iki farklı eğitim tarifiyle aldığı sonuçlar.

BULGU

Model aynı kalmış, yalnızca eğitim şekli değişmiştir; doğruluk %94,68'den %97,62'ye, macro F1 0,940'tan 0,972'ye çıkmıştır.




Domates 5 sınıf deneyi. Bu tarif daha sonra 38 sınıfa aynen uygulanmıştır.

Aynı EfficientNetB0 modelinin iki farklı eğitim tarifiyle aldığı sonuçlar.

BULGU

Model aynı kalmış, yalnızca eğitim şekli değişmiştir; doğruluk %94,68'den %97,62'ye, macro F1 0,940'tan 0,972'ye çıkmıştır.



Kesiklik çizgiler aşama geçişleri. Her geçişte küçük bir sıçrama var ama eğitim ve doğrulama çizgileri birbirinden ayrılmıyor.

Kademeli fine-tuning ile eğitimin epoch epoch ilerleyişi: solda 5 sınıf deneyi, sağda 38 sınıflı üretim modeli.

BULGU

Her aşama geçişinde küçük bir sıçrama olmuş ama doğrulama doğruluğu istikrarlı yükselmiştir; eğitim ve doğrulama çizgileri ayrılmamıştır, yani ezberleme görülmemektedir.

> Kod: kademeli fine-tuning döngüsü

← Model Karşılaştırma

6 / 11

Test Sonuçları (38 Sınıf) →

Ekranda ne var?

Her aşamada eğitilen parametre sayısı, aynı modelin iki farklı eğitim tarifiyle sonucu ve öğrenme eğrileri.

Nasıl okunur?

Parametre grafiğinde aşama ilerledikçe çubuk uzar, çünkü gövdenin daha fazlası eğitime açılır. Önce/sonra grafiğinde açık mavi ilk tarif, yeşil kademeli fine-tuning'dir.

Ne anlama geliyor?

Fine-tuning, hazır modelin son katmanlarını açıp çok küçük adımlarla yeniden eğitmektir. Kademeli yapıldığı için modelin hazır bilgisi bozulmamış; aynı model, yalnızca eğitim şekli değiştirilerek %94,7'den %97,6'ya çıkmıştır.

Test Sonuçları — Karışıklık matrisi (38 sınıf)

Test Sonuçları — 38 Sınıf


Test kümesi eğitimde hiç kullanılmamıştır. Model bu 8.146 görselin hepsinde yerel olarak yeniden çalıştırılmıştır; aşağıdaki tüm sonuçlar bu gerçek tahminlerden hesaplanmaktadır.

Test görseli 8.146	Doğruluk %98,98 ↑ Colab'da %99,02	Macro F1 0,9855	Yanlış tahmin 83	Ortalama güven %98,9
------------------------------	--	---------------------------	----------------------------	--------------------------------

Colab ile aradaki küçük fark (birkaç görsel) görsellerin 224×224'e küçültülmesinde kullanılan kütüphane farkından geliyor.

Karışıklık matrisi Sınıf bazında Güven ve eşik Yanlış bilinenler Colab grafikleri

☒ Sadece hataları göster (köşegeni gizle)



En sık karışan sınıflar

Gerçek	Tahmin	Adet
Mısır — Gri Yaprak Lekesi	Mısır — Kuzey Yaprak Yanıklığı	9
Mısır — Kuzey Yaprak Yanıklığı	Mısır — Gri Yaprak Lekesi	8
Domates — Erken Yanıklık	Domates — Hedef Leke	7
Domates — Erken Yanıklık	Domates — Septoria Yaprak Lekesi	5
Domates — Kırmızı Örümcek	Domates — Hedef Leke	4
Domates — Bakteriyel Leke	Domates — Hedef Leke	3
Domates — Bakteriyel Leke	Domates — Septoria Yaprak Lekesi	3
Domates — Geç Yanıklık	Domates — Erken Yanıklık	3
Domates — Erken Yanıklık	Patates — Geç Yanıklık	3
Domates — Geç Yanıklık	Patates — Geç Yanıklık	2

Karışmaların çoğu aynı bitkinin kendi hastalıkları arasında. Model bitkiyi neredeyse hiç şaşırmıyor, zorlandığı yer benzer görünen lekeler.

Karışıklık matrisi: satırlar gerçek sınıf, sütunlar modelin tahmini. 'Sadece hataları göster' açırken yalnızca yanlış tahminler çizilir.

BULGU

8.146 test görselinde 83 hata vardır: bunların 70'i aynı bitkinin kendi hastalıkları arasındadır. En sık karışma mucir'da gri yaprak lekesi ile kuzey yaprak yanıklığı.

En sık karışan sınıflar

Gerçek	Tahmin	Adet
Mısır — Gri Yaprak Lekesi	Mısır — Kuzey Yaprak Yanıklığı	9
Mısır — Kuzey Yaprak Yanıklığı	Mısır — Gri Yaprak Lekesi	8
Domates — Erken Yanıklık	Domates — Hedef Leke	7
Domates — Erken Yanıklık	Domates — Septoria Yaprak Lekesi	5
Domates — Kırmızı Örümcek	Domates — Hedef Leke	4
Domates — Bakteriyel Leke	Domates — Hedef Leke	3
Domates — Bakteriyel Leke	Domates — Septoria Yaprak Lekesi	3
Domates — Geç Yanıklık	Domates — Erken Yanıklık	3
Domates — Erken Yanıklık	Patates — Geç Yanıklık	3
Domates — Geç Yanıklık	Patates — Geç Yanıklık	2

Karışmaların çoğu aynı bitkinin kendi hastalıkları arasında. Model bitkiyi neredeyse hiç şaşırmıyor, zorlandığı yer benzer görünen lekeler.

Karışıklık matrisi: satırlar gerçek sınıf, sütunlar modelin tahmini. 'Sadece hataları göster' açırken yalnızca yanlış tahminler çizilir.

BULGU

8.146 test görselinde 83 hata vardır; bunların 70'i aynı bitkinin kendi hastalıkları arasındadır. En sık karışma mısırdaki gri yaprak lekesi ile kuzey yaprak yanıklığı arasındadır (iki yönde 17).

← Fine-Tuning

7 / 11

Model Nereye Bakıyor? →

Ekranda ne var?

Üstte test sonuçlarının özeti; ortada 38x38'lik karışıklık matrisi (yalnızca hatalar); altta en sık karışan sınıflar.

Nasıl okunur?

Satır gerçek sınıf, sütun tahmindir. Her renkli kare 'bu hastalık şu hastalıkla karıştırıldı' demektir; renk koyulaştıkça karışma artar. Örnek: gerçekte gri yaprak lekesi olan 9 yaprağa kuzey yaprak yanıklığı denmiştir.

Ne anlama geliyor?

8.146 test görselinde 83 hata vardır, 70'i aynı bitkinin kendi hastalıkları arasındadır. Model bitkiyi neredeyse hiç karıştırmaz; zorlandığı yer benzer lekeli hastalıklardır.

Test Sonuçları — Sınıf bazında başarı

Test Sonuçları — 38 Sınıf

Test kümesi eğitimde hiç kullanılmamıştır. Model bu 8.146 görselin hepsinde yerel olarak yeniden çalıştırılmıştır; aşağıdaki tüm sonuçlar bu gerçek tahminlerden hesaplanmaktadır.


Test görseli 8.146	Doğruluk %98,98 ↑ Colab'da %99,02	Macro F1 0,9855	Yanlış tahmin 83	Ortalama güven %98,9
------------------------------	--	---------------------------	----------------------------	--------------------------------

Colab ile aradaki küçük fark (birkaç görsel) görsellerin 224×224'e küçültülmesinde kullanılan kütüphane farkından geliyor.

Karşıklık matrisi Sınıf bazında Güven ve eşik Yanlış bilinenler Colab grafikleri

Metrik

☒ F1 ☐ Recall ☐ Precision




Turuncu: %97'nin altında kalan sınıflar. Precision: model "bu hastalık" dediğinde ne kadar haklı. Recall: gerçekten o hastalıkta olanların ne kadarını yakaladı.

38 sınıfın her biri için ayrı ayrı F1 (ya da seçilen metrik) değeri, küçükten büyüğe sıralı.

BULGU

Beş sınıf %97'nin altındadır; en düşükleri mısır gri yaprak lekesi (0,889) ve domates erken yanıklıktır (0,899). Bunlar birbirine çok benzeyen lekeli hastalıklardır.

Sınıf	Precision	Recall	F1	Test görseli
Mısır — Gri Yaprak Lekesi	89.47%	88.31%	88.89%	77
Domates — Erken Yanıklık	94.16%	86.00%	89.90%	150
Mısır — Kuzey Yaprak Yanıklığı	93.92%	93.92%	93.92%	148
Domates — Hedef Leke	91.67%	99.05%	95.22%	211
Domates — Mozaik Virüsü	100.00%	91.07%	95.33%	56
Domates — Septoria Yaprak Lekesi	95.64%	98.87%	97.23%	266
Patates — Sağıklık	100.00%	95.65%	97.78%	23
Domates — Kırmızı Örümcek	97.62%	98.01%	97.81%	251
Domates — Geç Yanıklık	98.58%	97.20%	97.89%	286



Turuncu: %97'nin altında kalan sınıflar. Precision: model "bu hastalık" dediğinde ne kadar haklı. Recall: gerçekten o hastalıkta olanların ne kadarını yakaladı.

38 sınıfın her biri için ayrı F1 (ya da seçilen metrik) değeri, küçükten büyüğe sıralı.

BULGU

Beş sınıf %97'nin altındadır; en düşükleri mısır gri yaprak lekesi (0,889) ve domates erken yanıklıktır (0,899). Bunlar birbirine çok benzeyen lekeli hastalıklardır.

Sınıf	Precision	Recall	F1	Test görseli
Mısır — Gri Yaprak Lekesi	89.47%	88.31%	88.89%	77
Domates — Erken Yanıklık	94.16%	86.00%	89.90%	150
Mısır — Kuzey Yaprak Yanıklığı	93.92%	93.92%	93.92%	148
Domates — Hedef Leke	91.67%	99.05%	95.22%	211
Domates — Mozaik Virüsü	100.00%	91.07%	95.33%	56
Domates — Septoria Yaprak Lekesi	95.64%	98.87%	97.23%	266
Patates — Sağlıklı	100.00%	95.65%	97.78%	23
Domates — Kırmızı Örümcek	97.62%	98.01%	97.81%	251
Domates — Geç Yanıklık	98.58%	97.20%	97.89%	286
Patates — Geç Yanıklık	96.77%	100.00%	98.36%	150

← Fine-Tuning

7 / 11

Model Nereye Bakıyor? →

Ekranda ne var?

38 sınıfın her birinin F1 (veya seçilen ölçü) değeri ve tablo.

Nasıl okunur?

Çubuk ne kadar kısaysa model o sınıfta o kadar zorlanıyor demektir; turuncu çubuklar %97'nin altındadır. Precision: model 'bu hastalık' dediğinde ne kadar haklı. Recall: gerçekten o hastalıkta olanların ne kadarını buldu.

Ne anlama geliyor?

Beş sınıf %97'nin altında kalmıştır; en zayıfları mısır gri yaprak lekesi (0,889) ve domates erken yanıklıktır (0,899). Diğer sınıfların çoğu %99'un üzerindedir.

Test Sonuçları — Güven ve eşik

Test Sonuçları — 38 Sınıf


Test kümesi eğitimde hiç kullanılmamıştır. Model bu 8.146 görselin hepsinde yerel olarak yeniden çalıştırılmıştır; aşağıdaki tüm sonuçlar bu gerçek tahminlerden hesaplanmaktadır.

Test görseli 8.146	Doğruluk %98,98 ↑ Colab'da %99,02	Macro F1 0,9855	Yanlış tahmin 83	Ortalama güven %98,9
------------------------------	--	---------------------------	----------------------------	--------------------------------

Colab ile aradaki küçük fark (birkaç görsel) görsellerin 224×224'e küçültülmesinde kullanılan kütüphane farkından geliyor.

Karşıklık matrisi Sınıf bazında **Güven ve eşik** Yanlış bilinenler Colab grafikleri

Doğru ve yanlış tahminlerde güven




Yanlış tahminlerde ortalama güven %71,2, doğrularda %99,2. Model yanlışla genelde daha az emin oluyor.

Modelin verdiği güven değerlerinin dağılımı; lacivert doğru, turuncu yanlış tahminler.

BULGU

Doğru tahminlerde ortalama güven %99,2, yanlışlarda %71,2'dir; model



Yanlış tahminlerde ortalama güven %71,2, doğrularda %99,2. Model yanlışla genelde daha az emin oluyor.

Modelin verdiği güven değerlerinin dağılımı; lacivert doğru, turuncu yanlış tahminler.

BULGU

Doğru tahminlerde ortalama güven %99,2, yanlışlarda %71,2'dir; model yanlışlarında genellikle daha az emindir. Yine de 20 yanlış tahminde güven %90'ın üzerindedir; güven eşiği tek başına yeterli değildir.

Uzmana yönlendirme eşiği

Güven eşiği (%)

70

Eşiğin üstünde (bot cevap verir)

%98.8

Bu gruptaki doğruluk

%99.49

Uzmaya yönlendirilen

99

Yakalanan yanlış

42 / 83

■ Cevap verilenlerde doğru... ■ Uzmaya giden oranı



Eşiğin üstünde (bot cevap verir)

%98.8

Bu gruptaki doğruluk

%99.49


Uzmaya yönlendirilen

99

Yakalanan yanlış

42 / 83

■ Cevap verilenlerde doğru... ■ Uzmaya giden oranı



Güven eşiği değiştiğinde iki şeyin nasıl değiştiği: cevap verilen tahminlerin doğruluğu (lacivert) ve uzmana gönderilen oran (yeşil).

BULGU

%70 eşiğinde tahminlerin %98,8'ine cevap verilmekte, bunların doğruluğu %99,5 olmaktadır; 83 hatanın 42'si uzmana gönderilerek yakalanmaktadır.

Botta eşik %70 olarak belirlenmiştir. Eşik yükseldikçe cevap verilen tahminler daha doğru olur ama daha fazla kullanıcı uzmana yönlendirilir. Bu bir denge kararıdır.

← Fine-Tuning

7 / 11

Model Nereye Bakıyor? →

Ekranda ne var?

Doğru ve yanlış tahminlerde modelin güven dağılımı ve %70 eşliğinin etkisini gösteren eğri.

Nasıl okunur?

Soldaki grafikte lacivert doğru, turuncu yanlış tahminlerdir. Sağdaki kaydırıcı eşliği değiştirir; eğerde lacivert çizgi cevap verilen tahminlerin doğruluğu, yeşil çizgi uzmana gönderilen oranıdır.

Ne anlama geliyor?

Model yanıldığında genellikle daha az emindir (ortalama %71, doğrularda %99). %70 eşliğinde tahminlerin %98,8'ine cevap verilir, bunların doğruluğu %99,5'tir; 83 hatanın 42'si uzmana gönderilerek yakalanır.

Test Sonuçları — Yanlış bilinenler

Test Sonuçları — 38 Sınıf

Test kümesi eğitimde hiç kullanılmamıştır. Model bu 8.146 görselin hepsinde yerel olarak yeniden çalıştırılmıştır; aşağıdaki tüm sonuçlar bu gerçek tahminlerden hesaplanmaktadır.

Test görseli 8.146	Doğruluk %98,98 ↑ Colab'da %99,02	Macro F1 0,9855	Yanlış tahmin 83	Ortalama güven %98,9
------------------------------	--	---------------------------	----------------------------	--------------------------------

Colab ile aradaki küçük fark (birkaç görsel) görsellerin 224×224'e küçültülmesinde kullanılan kütüphane farkından geliyor.

Karşıklık matrisi Sınıf bazında Güven ve eşik Yanlış bilinenler Colab grafikleri

Modelin yanlışlığı 83 test görseli. Güveni en yüksek olanlar en tehlikeli hatalar: model yanlış olduğu halde emin.

Sıralama

☒ Güveni en yüksek ☐ Güveni en düşük



Gerçek: Mısır — Kuzey Yaprak Yanıklığı
Tahmin: Mısır — Gri Yaprak Lekesi
Güven: %100



Gerçek: Domates — Bakteriyel Leke
Tahmin: Domates — Hedef Leke
Güven: %99



Gerçek: Domates — Sarı Yaprak Kıvrıklılığı Virüsü
Tahmin: Domates — Kırmızı Örümcek
Güven: %98



Gerçek: Mısır — Kuzey Yaprak Yanıklığı
Tahmin: Mısır — Gri Yaprak Lekesi
Güven: %97



Gerçek: Domates — Erken Yanıklık
Tahmin: Patates — Geç Yanıklık
Güven: %97



Gerçek: Domates — Kırmızı Örümcek
Tahmin: Domates — Hedef Leke
Güven: %96



Lekesi
Güven: %100



Leke
Güven: %99



Örümcek
Güven: %98



Lekesi
Güven: %97



Yanıklık
Güven: %97



Leke
Güven: %96



Gerçek: Mısır — Kuzey Yaprak Yanıklığı
Tahmin: Mısır — Gri Yaprak Lekesi
Güven: %95



Gerçek: Domates — Erken Yanıklık
Tahmin: Patates — Geç Yanıklık
Güven: %94



Gerçek: Domates — Erken Yanıklık
Tahmin: Domates — Bakteriyel Leke
Güven: %94



Gerçek: Domates — Geç Yanıklık
Tahmin: Soya — Sağlıklı
Güven: %94



Gerçek: Domates — Erken Yanıklık
Tahmin: Patates — Geç Yanıklık
Güven: %94




Gerçek: Domates — Erken Yanıklık
Tahmin: Domates — Septoria Yaprak Lekesi
Güven: %93



Gerçek: Domates — Erken Yanıklık
Tahmin: Domates — Septoria Yaprak Lekesi
Güven: %93



Gerçek: Domates — Mozaik Virüsü
Tahmin: Domates — Septoria Yaprak Lekesi
Güven: %93



Gerçek: Mısır — Gri Yaprak Lekesi
Tahmin: Mısır — Kuzey Yaprak Yanıklığı
Güven: %92



Gerçek: Domates — Bakteriyel Leke
Tahmin: Domates — Hedef Leke
Güven: %91



Gerçek: Domates — Bakteriyel Leke
Tahmin: Domates — Erken Yanıklık
Güven: %91



Gerçek: Mısır — Gri Yaprak Lekesi
Tahmin: Mısır — Kuzey Yaprak Yanıklığı
Güven: %91



Gerçek: Domates — Erken Yanıklık
Tahmin: Domates — Hedef Leke
Güven: %93



Gerçek: Mısır — Kuzey Yaprak Yanıklığı
Tahmin: Mısır — Gri Yaprak Lekesi
Güven: %93




Gerçek: Mısır — Gri Yaprak Lekesi
Tahmin: Mısır — Kuzey Yaprak Yanıklığı
Güven: %92




Gerçek: Domates — Kırmızı Örümcek
Tahmin: Domates — Hedef Leke
Güven: %91



Gerçek: Mısır — Gri Yaprak Lekesi
Tahmin: Mısır — Kuzey Yaprak Yanıklığı
Güven: %91



Gerçek: Domates — Bakteriyel Leke
Tahmin: Domates — Geç Yanıklık
Güven: %91

Tahmin: Mısır — Gri Yaprak Lekesi Güven: %95	Tahmin: Patates — Geç Yanıklık Güven: %94	Tahmin: Domates — Bakteriyel Leke Güven: %94	Tahmin: Soya — Sağıklı Güven: %94	Tahmin: Patates — Geç Yanıklık Güven: %94	Tahmin: Domates — Septoria Yaprak Lekesi Güven: %93
					
Gerçek: Domates — Erken Yanıklık Tahmin: Domates — Septoria Yaprak Lekesi Güven: %93	Gerçek: Domates — Mozaik Virüsü Tahmin: Domates — Septoria Yaprak Lekesi Güven: %93	Gerçek: Mısır — Gri Yaprak Lekesi Tahmin: Mısır — Kuzey Yaprak Yanıklığı Güven: %92	Gerçek: Domates — Bakteriyel Leke Tahmin: Domates — Hedef Leke Güven: %91	Gerçek: Domates — Bakteriyel Leke Tahmin: Domates — Erken Yanıklık Güven: %91	Gerçek: Mısır — Gri Yaprak Lekesi Tahmin: Mısır — Kuzey Yaprak Yanıklığı Güven: %91
					
Gerçek: Domates — Erken Yanıklık Tahmin: Domates — Hedef Leke Güven: %91	Gerçek: Mısır — Kuzey Yaprak Yanıklığı Tahmin: Mısır — Gri Yaprak Lekesi Güven: %91	Gerçek: Mısır — Gri Yaprak Lekesi Tahmin: Mısır — Kuzey Yaprak Yanıklığı Güven: %90	Gerçek: Domates — Kırmızı Örümcek Tahmin: Domates — Hedef Leke Güven: %88	Gerçek: Mısır — Gri Yaprak Lekesi Tahmin: Mısır — Kuzey Yaprak Yanıklığı Güven: %86	Gerçek: Domates — Bakteriyel Leke Tahmin: Domates — Geç Yanıklık Güven: %86

← Fine-Tuning

7 / 11

Model Nereye Bakıyor? →

Ekranda ne var?

Modelin yanıldığı gerçek test görselleri; her birinin altında gerçek sınıf, tahmin ve güven.

Nasıl okunur?

Varsayılan sıralamada en üstte güveni en yüksek hatalar vardır.

Ne anlama geliyor?

Güveni yüksek hatalar en tehlikelileridir: model yanlış olduğu hâlde emindir. Bu yüzden güven eşiği tek başına yeterli değildir; uzman kontrolü önemlidir.

Model Nereye Bakıyor? (Grad-CAM)

Model Nereye Bakıyor?

Grad-CAM yöntemiyle modelin kararında yaprağın hangi bölgesinin etkili olduğunu gösterilmektedir. Kırmızı bölgeler karara en çok etki eden yerlerdir. Model gerçekten lekelere bakıyorsa doğru şeyi öğrenmiş demektir; arka plana bakıyorsa bir sorun var demektir.

Görsel

☒ Test kümesinden ☐ Yüklenen fotoğraftan

Hangi tahminler?

☒ Doğru bilinenler ☐ Yanlış bilinenler

Gerçek sınıf

Ahududu — Sağlıklı

Örnek

1


1

56

Gerçek sınıf: Ahududu — Sağlıklı



Görsel



Grad-CAM

Modelin ilk 3 tahmini

Ahududu — Sağlıklı — %100.0

Çilek — Sağlıklı — %0.0

Kiraz — Sağlıklı — %0.0

Isı haritası 7x7'lik son evrişim çıktısından hesaplanıp görsel boyutuna büyütülüyor, bu yüzden kaba bir bölge gösteriyor.

Solda yaprak, ortada modelin karar verirken en çok baktığı bölgeleri gösteren ısı haritası, sağda modelin ilk 3 tahmini.


BULGU

Kırmızı bölge lekenin üzerindeyse model doğru şeyi bakmaktadır. Arka planda ya da yaprak sapındaysa model doğru bile bile kısa bir yol öğrenmiş olabilir; bu, tarla fotoğraflarında başarının düşebileceğinin işaretidir.

Gerçek sınıf: Ahududu — Sağlıklı



Görsel



Grad-CAM

Modelin ilk 3 tahmini

Ahududu — Sağlıklı — %100.0

Çilek — Sağlıklı — %0.0

Kiraz — Sağlıklı — %0.0

Isı haritası 7x7'lik son evrişim çıktısından hesaplanıp görsel boyutuna büyütülüyor, bu yüzden kaba bir bölge gösteriyor.

Solda yaprak, ortada modelin karar verirken en çok baktığı bölgeleri gösteren ısı haritası, sağda modelin ilk 3 tahmini.

BULGU

Kırmızı bölge lekenin üzerindeyse model doğru şeyi bakmaktadır. Arka planda ya da yaprak sapındaysa model doğru bile bile kısa bir yol öğrenmiş olabilir; bu, tarla fotoğraflarında başarının düşebileceğinin işaretidir.

Bulgu: Model çoğu örnekte lekelerle bakıyor (ör. domates geç yanıklığı, üzüm esca). Ama bazı örneklerde doğru tahmin ettiği halde yaprak sapına ya da kenardaki arka plana bakıyor (ör. mısır pası, elma kara çürüklüğü). PlantVillage'da aynı sınıfın fotoğrafları benzer koşullarda çekildiği için model arka plan gibi "kısa yollar" da öğrenebiliyor; literatürde bu veri setinde arka plan yanlılığı raporlanmış. Tarla fotoğraflarında başarının düşebileceğinin somut bir işareti.

← Test Sonuçları (38 Sınıf)

8 / 11

RAG ve Rapor →

Ekranda ne var?

Seçilen yaprak, üzerine modelin kararını en çok etkileyen bölgeleri gösteren ısı haritası ve ilk 3 tahmin.

Nasıl okunur?


Kırmızı ve sarı bölgeler kararı en çok etkileyen, mavi bölgeler en az etkileyen yerlerdir.

Ne anlama geliyor?


Kırmızı bölge lekenin üzerindeyse model doğru şeye bakıyordur. Bazı örneklerde (ör. mısır pası) model doğru bildiği hâlde arka plana bakar; bu, tarla fotoğraflarında başarının düşebileceğinin işaretidir.

RAG ve Rapor

Model sadece bir sınıf adı ve güven değeri veriyor. Çiftçiye anlaşılır bir rapor lazım. Rapor Claude tarafından yazılır, ama **ezberden değil**: önce proje için hazırlanan bilgi tabanından o hastalığa ait metin bulunuyor (RAG), Claude raporu bu metne dayanarak yazıyor.



Bilgi tabanı Canlı arama Kurallar ve örnek rapor



Bilgi tabanında her hastalık için kaç metin parçası bulunduğu.

BULGU

38 sınıfın hepsi için bilgi dosyası vardır; toplam 197 parça. Tahmin gelince o hastalığa ait en ilgili 2 parça Claude'a verilir ve rapor bu metne dayanarak yazılır.

Bilgi dosyası

Domates — Geç Yanıklık

Geç Yanıklık (Late Blight) — *Phytophthora infestans*

Etken: *Phytophthora infestans* (su küfü / oomycete — klasik anlamda mantar değildir, ama pratikte "mantar hastalığı" gibi ele alınır).

Belirtiler

- Yapraklarda düzensiz, sınırları belirsiz, su emmiş görünümlü **büyük** koyu yeşil/kahverengi lekeler.
- Nemli havada lekelerin alt yüzeyinde ince, beyazımsı bir küf tabakası (sporanma) görülebilir.
- Çok hızlı yayılır — uygun koşullarda birkaç gün içinde tüm bitkiyi/parseli etkileyebilir.
- Gövde ve meyvede kahverengi, sert lezyonlar oluşabilir.

Uygun koşullar

← Model Nereye Bakıyor?

9 / 11

Canlı Demo — Tarla 360 →

Bilgi tabanında her hastalık için kaç metin parçası bulunduđu.

BULGU

38 sınıfın hepsi için bilgi dosyası vardır; toplam 197 parça. Tahmin gelince o hastalığa ait en ilgili 2 parça Claude'a verilir ve rapor bu metne dayanarak yazılır.

Bilgi dosyası

Domates — Geç Yanıklık

Geç Yanıklık (Late Blight) — *Phytophthora infestans*

Etken: *Phytophthora infestans* (su küfö / oomycete — klasik anlamda mantar değildir, ama pratikte "mantar hastalığı" gibi ele alınır).

Belirtiler

- Yapraklarda düzensiz, sınırları belirsiz, su emmiş görünümlü **büyük** koyu yeşil/kahverengi lekeler.
- Nemli havada lekelerin alt yüzeyinde ince, beyazımsı bir küf tabakası (sporlanma) görülebilir.
- Çok hızlı yayılır — uygun koşullarda birkaç gün içinde tüm bitkiyi/parseli etkileyebilir.
- Gövde ve meyvede de kahverengi, sert lezyonlar oluşabilir.

Uygun koşullar

← Model Nereye Bakıyor?

9 / 11

Canlı Demo — Tarla 360 →

Ekranda ne var?

Bilgi tabanının özeti, her hastalık için metin parçası sayısı ve açılabilen bir bilgi dosyası.

Nasıl okunur?

Her çubuk bir hastalığın bilgi dosyasının kaç parçaya bölündüğünü gösterir.

Ne anlama geliyor?

38 hastalığın hepsi için bilgi dosyası vardır (toplam 197 parça). Model bir hastalık bulduğunda o hastalığın en ilgili 2 parçası Claude'a verilir ve rapor bu metne dayanarak yazılır; buna RAG denir.